

第1章 機械学習入門

演習問題

解答 1.1

機械学習が有効に機能するためには、以下のような特徴が重要である。

第一に、入力と出力の間に一定のパターンや規則性が存在することである。完全にランダムな関係では学習は成立しない。

第二に、十分な量のデータが存在することである。少量のデータでは汎化性能の高いモデルを構築することが難しい。

第三に、予測したい対象（目的変数）が明確に定義されていることである。曖昧な目標では学習の方向性が定まらない。

これらはすべて、機械学習が「過去のデータからパターンを学習する」という性質に起因する。

解答 1.2

適しているのは (2) と (4) である。(2) は過去の顧客データから解約の傾向を学習できるため、機械学習が有効である。(4) は画像データから特徴を抽出し分類する問題であり、典型的な機械学習の適用領域である。

一方で (1) は数学的に厳密な解法が存在するため、機械学習を用いる必要はない。(3) はルールベースで完全に定義できるため、機械学習よりもルールエンジンの方が適している。

解答 1.3

回帰問題は、出力が連続値である問題である。例えば売上予測や気温予測などが該当する。分類問題は、出力が離散的なカテゴリである問題である。例えばスパム判定や顧客の離反有無などが該当する。この違いにより、使用する損失関数や評価指標が異なる。

解答 1.4

機械学習は、過去データに含まれる入力と出力の関係性（パターン）を学習する。このとき、データ生成の背後にある構造が時間を通じて大きく変化しない（分布が安定している）という前提がある。この前提のもとでは、過去に観測された関係性が将来にも適用できるため、予測が可能となる。逆に、この前提が崩れる場合（データ分布の変化など）には、予測精度が低下する。

解答 1.5

この状況では、学習データと現在のデータの分布が異なる可能性が高い。機械学習は過去データのパターンを前提としているため、その前提が崩れると予測が適しなくなる。これはデータドリフトやコンセプトドリフトと呼ばれる問題であり、モデルの再学習や特徴量の見直しが必要となる。

一方で、実測した結果、予測性能が維持されていた場合、以下のようなことが考えられる。

- ・ ビジネス環境の変化がモデルに影響を与えない範囲であった。利用していた変数には変化の影響が少なかった。
- ・ モデルが変化に対して頑健であった。正則化や特徴量選択などにより、過学習を防ぐ設計がされていた。
- ・ 学習データが変化を十分にカバーしていた。過去のデータに変化の兆候が含まれていた可能性がある。

解答 1.6

このモデルは「広告を出した結果の売上」を学習しているが、「広告を出さなかった場合との比較」が考慮されていない。そのため、もともと購買意欲の高い顧客を高く評価するだけになり、広告の効果を正しく評価できない可能性がある。これは相関と因果の違いの問題であり、施策の意思決定には注意が必要である。

解答 1.7

精度が高くても、それがビジネス価値に直結するとは限らないためである。例えば、誤分類のコストが非対称な場合や、意思決定の閾値が重要な場合には、単純な精度では不十分である。また、モデルの解釈性や運用可能性、データ取得コストなども重要な要素となる。

解答 1.8

ここでは、機械学習を使うべきかどうかを判断するための観点を3つ挙げて説明する。

第一に、ルールで明確に定義できるかどうかである。明確なルールがある場合は機械学習は不要である。

第二に、データが十分に存在するかどうかである。データが不足している場合は学習が難しい。

第三に、予測の価値があるかどうかである。予測結果が意思決定に活用されない場合は導入の意義が低い。

これらを総合的に判断することが重要である。

第2章 データ理解と特徴量設計

演習問題

基礎問題（概念理解）

解答 2.1

EDA の目的は、データの分布、欠損、外れ値、変数間の関係などを理解することである。EDA を行わない場合、データの性質を誤解したままモデリングを行うことになり、不適切な前処理や特徴量設計につながる。その結果、モデルの精度低下や誤った解釈を招く可能性がある。

解答 2.2

平均値はすべての値の合計をデータ数で割ったものであり、外れ値の影響を受けやすい。中央値はデータを並べたときの中央の値であり、外れ値の影響を受けにくい。外れ値が存在する場合は中央値が適しており、分布が対称で外れ値が少ない場合は平均値が適している。

解答 2.3

標準化とは、変数の平均を 0、標準偏差を 1 にスケーリングする処理である。スケールの異なる変数が存在する場合、距離ベースの手法や勾配ベースの最適化において影響が偏るため、標準化が必要となる。具体的な手法としては、Z スコア標準化（平均 0、標準偏差 1 に変換）や最小最大スケーリング（0 から 1 の範囲に変換）がある。

解答 2.4

外れ値とは、他のデータと比較して極端に異なる値である。

測定ミスや入力ミスによる外れ値は当該レコードごと除去すべきである。

一方で、実際に起こりうる重要な事象（高額取引など）の場合は、そのまま保持すべきである。本番運用で同様の外れ値が発生する可能性があるため、モデルがそれに対応できるようにすることが重要である。

解答 2.5

ここでは、欠損値が発生する主な原因を 3 つ挙げて説明する。

第一に、データ取得時の失敗や記録漏れである。対処法は、平均値や中央値で補完する方法がある。

第二に、特定の条件で値が存在しない構造的欠損である。対処法は、欠損値を特定のカテゴリとして扱う方法や、条件に応じた補完方法がある。

第三に、意図的な未回答（アンケートなど）である。対処法は、欠損値を特定のカテゴリとして扱う方法や、他の変数から推定する方法がある。

原因に応じて適切な処理方法を選択する必要がある。単純に削除するのは、データの偏りを生む可能性があるため注意が必要である。

解答 2.6

多くの機械学習モデルは数値入力を前提としているため、カテゴリ変数をそのまま扱うことができない。そのため、ワンホットエンコーディングなどを用いて数値表現に変換する必要がある。

解答 2.7

第一に、カテゴリ数が多い場合に次元が増加し、計算コストが増大することである。

第二に、カテゴリ間の関係性を表現できないことである。

解答 2.8

特徴量エンジニアリングとは、元のデータから予測に有用な新しい変数を作成することである。適切な特徴量を設計することで、モデルの性能は大きく向上するため、機械学習において最も重要な工程の一つである。

EDA はデータの理解を深めるためのプロセスであり、特徴量エンジニアリングはその理解をもとに新しい特徴量を作成するプロセスである。EDA は特徴量エンジニアリングの前段階であり、データの性質を理解することで、どのような特徴量が有用かを考えることができる。特徴量エンジニアリングは、単なるデータ変換ではなく、ドメイン知識や創造性を活かして新しい情報を抽出するプロセスである。

特徴量エンジニアリングを進める中では、EDA を繰り返し行うことで、作成した特徴量の分布や目的変数との関係を確認し、さらに改善していくことが重要である。

解答 2.9

多重共線性により、モデルの係数が不安定になる可能性がある。また、解釈が困難になり、どの変数が重要か判断しづらくなる。対処法としては、相関の高い変数のうち一方を削除する、主成分分析（PCA）などの次元削減を行う、正則化を導入するなどがある。

解答 2.10

過去の値が現在の値に影響を与える場合、その情報をモデルに取り込むためである。ラグ特徴量により、時系列の依存関係を表現できる。

解答 2.11

分布が歪んでいると、モデルがその変数を適切に扱えない可能性がある。例えば、線形モデルでは正規分布を前提としているため、歪んだ分布の変数は予測性能を低下させる可能性がある。対処法としては、対数変換や Box-Cox 変換などの変換を行う方法がある。

実習問題：Telco Customer Churn

解答 2.12

Churn の割合を確認すると、1 869/7 043 (約 26.5%) が解約 (Yes) であり、非解約 (No) が多数を占める。これはクラス不均衡の問題を示しており、単純な精度 (accuracy) では適切な評価ができない可能性がある。そのため、Recall や Precision、ROC-AUC などの指標を検討する必要がある。

解答 2.13

数値変数は次の 3 つである。

- `tenure`: 顧客の在籍月数
- `MonthlyCharges`: 月額料金
- `TotalCharges`: 累計料金

まず、`TotalCharges` はスペースを含むため、文字列型として読み込まれることがある。これを数値型に変換する際に、スペースを欠損値として扱う必要がある。この際、`TotalCharges` が欠損しているにもかかわらず、`MonthlyCharges` が存在する場合は、`TotalCharges` を `MonthlyCharges x tenure` で補完することが考えられる。

ヒストグラムや箱ひげ図を用いて分布を確認する。分布の形状としては

- `tenure` は短期契約が多く、長期契約が少ないため、右に裾の長い分布になっている。
- `MonthlyCharges` は \$30 以下の低額の顧客と、\$80 辺りの中高額の顧客の 2 つにピークを持っている。
- `TotalCharges` は高額側に裾が長い分布になっている。

今回のデータでは、外れ値は特に見られないが、分布の歪みがあるため、モデルによっては対数変換などを検討することが有効である。

解答 2.14

可視化手法としては、数値変数を目的変数ごとに色分けしたヒストグラムや箱ひげ図、散布図やバイオリンプロットが有効である。もしくは、前問で作成したヒストグラムに目的変数ごとの割合を重ねる方法もある。

- `tenure` は、短期間の顧客ほど解約率が高い傾向が見られる。

- **MonthlyCharges** は、複数ピークが見られるが、月額料金が低い顧客ほど解約率が高い傾向が見られる。
- **TotalCharges** は、累計料金が低い顧客ほど解約率が低い傾向が見られる。

解答 2.15

今回、カテゴリ変数は 16 変数存在する。欠損もなく、極端に偏ったカテゴリもないため、すべての変数について分析することができる。全変数を列挙することはしないが、特に **Contract** と **PaymentMethod** また **Internet Service** の理由有無は、値ごとの解約率が大きく異なるため、解約率予測に大きな影響を与える可能性がある。

解答 2.16

カテゴリ変数のエンコーディング方法は、モデルの種類や変数の性質によって異なる。今回のカテゴリ変数は、すべて名義変数であるため、ワンホットエンコーディングが一般的に適している。値のカテゴリ数も最大で 3 程度であるため、次元の爆発も起こりにくい。

一方で、順序性がないため、ラベルエンコーディングは適していない。誤った順序性をモデルに与える可能性があるためである。ターゲットエンコーディングは、カテゴリ数が多い場合や、カテゴリごとのサンプル数が少ない場合に有効であるが、今回のデータでは必要性は低く、優先度は高くない。

実習問題：House Prices

解答 2.17

SalePrice の分布は右に裾の長い（右歪）分布となっている。すなわち、高価格帯の物件が少数存在し、分布が非対称である。このような分布では、

- 大きな値がモデルに強く影響する
- 残差の分布が歪む

といった問題が生じる。そのため、対数変換 ($\log(\text{SalePrice})$) や Box-Cox 変換を行うことで分布を正規分布に近づけることが有効である。

解答 2.18

ヒストグラムや箱ひげ図を用いることで分布の形状を確認できる。

多くの数値変数は右に裾の長い分布を持つ。例えば **LotArea** や **MasVnrArea** は、大きな値を持つ物件が少数存在するため、強い歪みが見られる。

また、散布図を用いることで外れ値を確認することができる。例えば、**GrLivArea** が非常に大きいにもかかわらず **SalePrice** が低いデータは外れ値候補となる。

これらの特徴から、対数変換や外れ値処理を検討する必要がある。

解答 2.19

散布図が最も有効である。例えば、**GrLivArea**（居住面積）と **SalePrice** の間には強い正の相関が見られる。

また、**OverallQual**（住宅品質）はカテゴリに近い離散値であるが、値が大きいほど価格が高くなる傾向が明確に見られる。

一方で、**LotFrontage** などは分布の歪みが大きく、関係が分かりにくいいため、対数変換を行うことで関係性が明確になる場合がある。

解答 2.20

カテゴリ変数ごとの **SalePrice** の分布を箱ひげ図などで可視化することで、価格との関係を確認できる。

例えば、

- **Neighborhood** は立地を表し、価格に強い影響を持つ
- **HouseStyle** は建物構造に関係し、価格差を生む
- **GarageType** は利便性を反映し、価格に影響する

また、欠損値が「存在しない（例：ガレージなし）」ことを意味する場合もあるため、単純な補完ではなく意味を考慮する必要がある。

解答 2.21

House Prices データではカテゴリ数が多い変数（例：**Neighborhood**）が存在するため、単純なワンホットエンコーディングでは次元が増大する可能性がある。

そのため、

- カテゴリ数が少ない変数：ワンホットエンコーディング
- カテゴリ数が多い変数：ターゲットエンコーディングや頻度エンコーディング

などを使い分けることが有効である。

Telco データではカテゴリ数が少なかったためワンホットエンコーディングで十分であったが、本データではより高度なエンコーディング手法の検討が必要となる。

解答 2.22

GrLivArea が極端に大きいにもかかわらず **SalePrice** が低いデータなどは外れ値候補となる。外れ値の除外は、

- 明らかに異常値（入力ミスなど）
- モデルに悪影響を与える場合

に限定すべきである。

一方で、高価格帯の物件などは実際のビジネス上重要なデータであるため、単純に除外すべきではない。

第3章 予測モデルの全体像

演習問題

基礎問題（概念理解）

解答 3.1

機械学習における学習とは、入力と出力の関係を表す関数を、データから推定することである。具体的には、過去のデータから計算される予測値と実測値の差 (予測誤差) を最小化するようにモデルのパラメータを調整することである。予測誤差を定量化するための関数が損失関数であり、最適化はこの損失関数を最小化するパラメータを見つけるプロセスである。このプロセスにより、新しいデータに対しても適切な予測ができるようになる。

解答 3.2

損失関数とは、予測値と実測値の誤差を定量化する関数である。モデルの学習は、この損失関数を最小化する問題として定式化される。損失関数があることで、モデルの良し悪しを数値的に評価し、最適なパラメータを求めることができる。

解答 3.3

MAE は誤差の絶対値を用いるため、外れ値の影響を受けにくい。一方、MSE は誤差を二乗するため、外れ値に敏感である。外れ値が多い場合は MAE、精度の高い予測を重視する場合は MSE が適している。

解答 3.4

損失関数は、ある確率分布を仮定したときの尤度最大化と対応している。例えば、二乗誤差は誤差が正規分布に従うという仮定に対応する。このように、損失関数の選択はデータの生成過程に関する仮定を含んでいる。

クロスエントロピーは確率的な解釈を持ち、分類問題における尤度最大化と対応している。また、誤分類に対して適切なペナルティを与えるため、学習が安定しやすい。一方、二乗誤差は確率としての解釈が弱く、分類問題には適していない場合が多い。

解答 3.5

モデルが複雑すぎる場合、モデルが訓練データに過度に適合し、ノイズまで学習してしまう。その結果、新しいデータに対する予測性能（汎化性能）が低下する。これは過学習（オーバーフィッティング）と呼ばれる問題である。

逆にモデルの複雑さが低すぎる場合、モデルがデータの本質的なパターンを捉えられず、予測精度が低くなる。これはアンダーフィッティングと呼ばれる。

解答 3.6

最適化とは、損失関数を最小化するパラメータを見つけるプロセスである。教師あり学習では、モデルのパラメータを調整して予測誤差を最小化することが目的であり、最適化はそのために必要である。最適化には様々なアルゴリズムが存在し、それぞれ特徴や適用条件が異なる。

解答 3.7

勾配降下法は、損失関数の勾配（傾き）を用いて、値が減少する方向にパラメータを更新する方法である。これを繰り返すことで、損失関数の最小値に近づいていく。

確率勾配流加法は、全データを用いるのではなく、ランダムに選んだ一部のデータ（ミニバッチ）を用いて勾配を計算する方法である。メリットは、計算コストが低く、収束が速いことがある。また確率的な更新により、局所最適解を回避しやすいこともある。デメリットは、更新がノイズを含むため、収束が不安定になる可能性があることや、最適解に到達しないことがある。

解答 3.8

ベースラインモデルとは、単純な手法で構築された基準となるモデルである。複雑なモデルの性能が本当に改善しているかを判断するために、その名の通りベースラインとなる評価基準を提供する。

平均値を予測するモデルは、データの分布のみを利用した最も単純なモデルである。これを基準とすることで、より複雑なモデルがどれだけ追加の情報を活用できているかを評価できる。

解答 3.9

原因は過学習である可能性がある。訓練データに過度に適合し、汎化性能が低下している恐れがある。対策としては、モデルの簡素化、正則化、データの増加、交差検証の利用などがある。

別の可能性として、データリークがある場合も考えられる。訓練データに新しいデータの情報が含まれていると、モデルが不正に高い精度を示すことがある。この場合の対策は、データの分割方法を見直し、訓練データとテストデータが完全に独立していることを確認することである。

最後に、データの分布が変化している可能性もある。訓練データと新しいデータの分布が異なる場合、モデルの性能が低下することがある。この場合の対策は、モデルの再学習や、分布の変化に対応できるようなモデルの設計を検討することである。

実習問題：Telco Customer Churn

解答 3.10

前処理としては最低限以下のものを実施する。

- 欠損値の処理（例：平均値で補完）：欠損値があるとモデルの学習に支障が出るため、適切な方法で処理する必要がある。
- カテゴリ変数のエンコード（例：ワンホットエンコード）：ロジスティック回帰は数値入力为前提としているため、カテゴリ変数を数値に変換する必要がある。
- 数値変数のスケーリング（例：標準化）：数値変数のスケールが異なると、モデルの学習が不安定になることがあるため、スケーリングを行うことが望ましい。

ロジスティック回帰の出力は確率であり、ある顧客が解約する確率を表す。この確率は意思決定（施策対象の選定）に利用される。

解答 3.11

分類モデルであるため、まず全体的な性能評価のために ROC 曲線と AUC を確認することが重要である。さらに、クラスの不均衡がある場合は、正解率だけでなく、精度、再現率、F1 スコアなどの指標も確認することが望ましい。これらの指標をテストデータに対して確認することで、モデルが新しいデータに対してどれだけ適切に予測できるか（汎化性能）を評価することができる。例えば、テストデータで AUC が高い場合、モデルはクラスを適切に区別できていると判断できる。また、精度が高いが再現率が低い場合は、モデルが解約する顧客を見逃している可能性があるため、ビジネスの目的に応じて指標を選択することが重要である。

解答 3.12

係数が正であれば解約確率を高め、負であれば低下させる。例えば月額料金が高いほど解約しやすいなどの解釈が可能である。またロジスティック回帰の係数は、特徴量が 1 単位増加したときのオッズ比の対数であるため、解約確率に与える影響を定量的に評価することもできる。この値が大きすぎる場合、モデルが過学習している可能性があるため、注意が必要である。

解答 3.13

クロスエントロピー損失を使用することで、モデルの性能が向上することが期待される。二乗誤差は分類問題には適していないため、性能が低下する可能性がある。実際にモデルを再構築し、テストデータに対する評価指標を比較することで、損失関数の選択がモデルの性能に与える影響を確認できる。

また最適化アルゴリズムを変更することで、収束速度や最終的な性能に違いが出ることがある。例えば、確率勾配流加法を使用することで、収束が速くなる可能性があるが、ノイズの影響で性能が不安定になることがある。

実習問題：House Prices

解答 3.14

前処理としては最低限以下のものを実施する。

- 欠損値の処理（例：平均値補完、またはカテゴリとして扱う）：欠損が多く存在するため適切な処理が必要である。
- カテゴリ変数のエンコード（例：ワンホットエンコード）：線形回帰は数値入力を前提としているため必要である。
- 数値変数のスケーリング（必要に応じて）：線形回帰では必須ではないが、正則化を用いる場合は必須である。

線形回帰モデルの出力は連続値であり、住宅の予測価格（SalePrice）を表す。この値は実際の価格との差（誤差）として評価され、価格設定や投資判断に利用される。

解答 3.15

回帰問題であるため、RMSE（Root Mean Squared Error）や MAE（Mean Absolute Error）が代表的な指標となる。

RMSE は大きな誤差に対して強いペナルティを与えるため、高価格物件の誤差を重視する場合に適している。一方、MAE は外れ値に対してロバストであり、全体的な誤差を評価するのに適している。

テストデータでの指標を確認することで、モデルの汎化性能を評価できる。訓練データに対しては誤差が小さいが、テストデータで大きくなる場合は過学習が疑われる。

解答 3.16

係数が正であれば、その特徴量が増加すると価格が上昇し、負であれば価格が低下することを意味する。例えば、GrLivArea の係数が正であれば、居住面積が大きいほど価格が高くなることを示す。

ただし、係数の解釈には以下の注意が必要である。

- 特徴量間の相関（多重共線性）があると係数の解釈が不安定になる
- スケールの違いにより係数の大きさを直接比較できない
- 非線形関係がある場合、線形モデルの係数では十分に表現できない

解答 3.17

対数変換を行うことで、目的変数の分布がより対称に近づく。その結果、残差の分布も改善され、モデルの仮定（誤差の正規性）がより満たされることがある。また、RMSE が改善する場合も多い。これは、極端に高価格なデータの影響が緩和されるためである。ただし、予測値は対数スケールで出力されるため、最終的には指数関数を用いて元のスケールに戻す必要がある。

解答 3.18

MSE は大きな誤差に対して強いペナルティを与えるため、外れ値に敏感である。そのため、高価格物件の誤差を重視する場合に適している。

一方、MAE は外れ値に対してロバストであり、全体的な誤差を均等に扱うため、安定した予測が求められる場合に適している。

実際にモデルを比較することで、用途に応じた損失関数の選択の重要性を確認できる。

第4章 モデル評価と検証

演習問題

基礎問題（概念理解）

解答 4.1

モデル評価の目的は、未知データに対する予測性能（汎化性能）を測定することである。訓練データでの性能は、そのデータに適合した結果に過ぎず、過学習の影響を受ける可能性がある。そのため、未知データに近い条件で評価することが重要である。

解答 4.2

クラス不均衡がある場合、Accuracy は実際の性能を正しく反映しない。例えば、99%が負例のデータでは、すべて負例と予測しても 99%の Accuracy となるが、有用なモデルとは言えない。そのため、Precision や Recall などの指標も併用する必要がある。

解答 4.3

Precision は予測した正例のうち実際に正しい割合である。Recall は実際の正例のうち正しく予測できた割合である。Precision は誤検知の少なさ、Recall は見逃しの少なさを表す。例えば、スパムメールの検知では誤検知を減らすために Precision を重視することが多い。一方、病気の診断では見逃しを減らすために Recall を重視することが多い。

F1 スコアは Precision と Recall の調和平均であり、両者のバランスを評価する指標である。両者のバランスを評価したい場合に有効であり、どちらか一方に偏らないモデルを評価できる。

解答 4.4

ROC 曲線は、偽陽性率と真陽性率の関係を表したものである。AUC はその曲線の下で面積であり、モデルの識別能力を表す。AUC が大きいほど、正例と負例をうまく区別できていることを意味する。一方で AUC は序列性能を評価するものであり、実際の確率値を表していない状態でも高い値を示すことがある。

AUC は全体的な識別能力を示すが、実際の運用では特定の閾値での性能が重要となる。また、クラス不均衡やコスト構造を反映していないため、ビジネス価値と一致しない場合がある。

解答 4.5

train はモデルの学習に使用する。

validation はハイパーパラメータの調整やモデル選択に使用する。

test は最終的な性能評価に使用し、モデル構築には使用しない。

解答 4.6

validation データに対して過適合する可能性がある。その結果、validation では高い性能を示すが、未知データでは性能が低下する。これを防ぐためには、test データを最終評価のみに使用し、validation データはモデル選択のみに使用することが重要である。

解答 4.7

交差検証は、データを複数の分割に分けて学習と評価を繰り返すことで、より安定した性能評価を得る方法である。データの分割によるばらつきを抑えることが目的である。単純に train/test に分割するだけでは、分割の仕方によって性能が大きく変わる可能性があるため、交差検証を用いることで、より一般的な性能評価が可能となる。

解答 4.8

Stratified K-Fold 交差検証は、各分割においてクラスの割合を維持する方法である。通常の K-Fold 交差検証では、クラス不均衡がある場合に、分割によっては特定のクラスが極端に少ない分割ができてしまう可能性がある。Stratified K-Fold はこれを防ぎ、各分割でクラスの分布がほぼ同じになるようにする。これにより、より安定した性能評価が可能となる。そのため、分類問題においては Stratified K-Fold がほぼデファクトスタンダードとなっており、通常の K-Fold よりも優先して使用される。

解答 4.9

データリークとは、本来利用できない情報（未来の情報や目的変数に直接関係する情報）がモデルに含まれてしまうことである。これにより、モデルの性能が過大評価される可能性がある。データリークは、例えば、データ前処理の段階で全データを使用して平均値を計算し、その値で欠損値を補完する場合などに発生しやすい。対策としては、データ分割を先に行い、学習データのみを使用して前処理を行うことが重要である。また、時系列データにおいては、未来の情報が過去の学習に含まれないように、時間順を維持した分割を行うことも重要である。

解答 4.10

検証データの情報が学習に含まれているため、データリークが発生している。正しくは、学習データのみで平均を計算し、その値を用いて補完する必要がある。交差検証を行う場合は、各分割ごとに学習データのみで平均を計算し、その値で補完する必要がある。

解答 4.11

未来の情報が過去の学習に含まれる可能性があり、データリークが発生する。時系列では時間順を維持した分割が必要である。交差検証においても、時間順を維持した分割方法（例えば `TimeSeriesSplit` など）を使用することが重要である。この場合、Fold ごとに学習データが増えていく形になるため、モデルの性能が時間の経過とともにどのように変化するかも評価できる。

解答 4.12

顧客のビジネスモデルやコスト構造に応じて、柔軟に適切な指標を設計することが重要であるが、以下では一般的な指標の例を示す。

- 1: 「不正取引の検知」不正取引の見逃しは大きな損失につながるため、Recall を重視すべきである。一方で誤検知もコストがかかるため、Precision とのバランスを考慮し、F1 スコアなども有効である。最終的にはビジネスコストを考慮した指標設計が重要である。
- 2: 「広告のクリック予測」広告のクリックは比較的稀なイベントであるため、クラス不均衡が存在する可能性が高い。そのため、Precision や Recall を重視することが重要である。また、広告の効果を評価するためには、AUC も有効な指標となる。
- 3: 「顧客の解約予測」解約する顧客を見逃すことはビジネスにとって大きな損失につながるため、Recall を重視すべきである。一方で、誤検知もコストがかかるため、Precision とのバランスを考慮し、F1 スコアなども有効である。最終的にはビジネスコストを考慮した指標設計が重要である。

解答 4.13

- 1: Accuracy が高いが Recall が低い。正例の検出が不十分であり、多くの正例を見逃している可能性がある。クラス不均衡の影響で Accuracy が高く見えている可能性もある。この場合、モデルの実用性には注意が必要である。
- 2: AUC が高いが Precision と Recall が低い。モデルは全体的にはクラスを区別できているが、特定の閾値での性能が低い可能性がある。これは、モデルの出力が確率として適切にキャリブレーションされていない可能性がある。また、クラス不均衡の影響で AUC が高く見えている可能性もあるため、実際の運用においては注意が必要である。
- 3: 交差検証の Fold ごとに性能が大きくばらついている。データの分割によるばらつきが大きい可能性がある。モデルが特定のデータセットに過適合している可能性もあるため、より安定した性能評価のために、データの前処理や特徴量選択を見直す必要がある。

実習問題：Telco Customer Churn

解答 4.14

AUC はランダムな正例と負例を選んだときに、正例のスコアが高くなる確率を表す。ROC 曲線の形状は、モデルの性能を視覚的に評価するのに役立つ。

例えば、ROC 曲線が左上に近いほど性能が高いことを示す。AUC が 0.5 に近い場合は、モデルの性能がランダムな予測と同程度であることを示す。AUC が高い場合でも、ROC 曲線の形状を確認することで、特定の閾値での性能が低い可能性があることに注意する必要がある。

また AUC は全体的な識別能力を表すため、同じ AUC でも ROC 曲線の形状が異なる場合があることに留意する必要がある。例えば、AUC が同じでも、あるモデルは高い Recall を持ち、別のモデルは高い Precision を持つ場合がある。今回の場合、Churn の予測においては、見逃しを減らすことが重要なため、ROC 曲線の形状を確認し、特に高い Recall を持つモデルを評価することが重要である。

解答 4.15

threshold を下げると Recall は上がるが Precision は下がる。逆も同様であり、用途に応じた調整が必要である。今回の場合、Churn の予測においては、見逃しを減らすことが重要なため、Recall を重視することが多い。しかし、誤検知もコストがかかるため、Precision とのバランスを考慮する必要がある。

F1 スコアは、Precision と Recall の調和平均であり、両者のバランスを評価する指標である。両者のバランスを評価したい場合に有効であり、どちらか一方に偏らないモデルを評価できる。例えば、Churn の予測においては、見逃しを減らすことが重要であるが、誤検知もコストがかかるため、F1 スコアを用いて両者のバランスを評価することが有効である。

解答 4.16

Train データに対する誤差が小さく、Test データで誤差が大きい場合、過学習が疑われる。逆に、両者の誤差が大きい場合は、モデルの表現力が不足している可能性がある。Train/Test の差を確認することで、モデルの汎化性能を評価できる。

解答 4.17

Fold ごとの性能のばらつきが大きい場合、データの分割による影響が大きい可能性がある。これは、モデルが特定のデータセットに過適合している可能性があるため、より安定した性能評価のために、データの前処理や特徴量選択を見直す必要がある。

Fold 数を増やすと、より多くのデータを学習に使用できるため、性能が向上する可能性があるが、計算コストも増加するため、適切な Fold 数を選択する必要がある。一般的な Fold 数は 5 や 10 が多いが、データセットのサイズや計算リソースに応じて調整することが望ましい。今回の 7000 件程度のデータセットでは、Fold 数=5 程度で十分な性能評価が可能であると考えられる。

Stratified K-Fold を用いると、各 Fold でクラスの割合が維持されるため、通常の K-Fold と比較して、より安定した性能評価が可能となる。特にクラス不均衡がある場合には、Stratified K-Fold を使用することが推奨される。

実習問題：House Prices

解答 4.18

RMSE は大きな誤差に対して強いペナルティを与える指標であり、高価格帯の物件の予測誤差を重視する場合に適している。一方、MAE は誤差の絶対値の平均であり、外れ値の影響を受けにくく、全体的な予測精度を評価するのに適している。

両者の値を比較することで、

- RMSE が MAE より大きい場合：大きな誤差（外れ値）の影響が強い
- 両者が近い場合：誤差が比較的均等に分布している

といった解釈が可能である。

解答 4.19

予測値と実測値をプロットした散布図において、対角線 ($y = \hat{y}$) に近いほど性能が高い。

以下のようなパターンが見られる場合、問題があると判断できる：

- 特定の価格帯で誤差が大きい（モデルの表現不足）
- 高価格帯で予測が過小評価される（非線形性）
- 全体的にバイアスがある（系統誤差）

解答 4.20

残差は平均 0 付近に対称な分布を持つことが望ましい。また、分散が一定である（異分散性がない）ことも重要である。

もし残差に偏りがある場合や、特定の領域で分散が大きい場合、モデルの仮定（線形性や等分散性）が満たされていない可能性がある。

解答 4.21

対数変換を行うことで、目的変数の分布が正規分布に近づき、残差の分布が改善されることがある。

その結果、RMSE や MAE が改善する場合がある。特に、極端に高価格なデータの影響が緩和されるため、モデルの安定性が向上する。

ただし、対数スケールで評価した場合と元のスケールで評価した場合では指標の意味が異なるため、評価時には注意が必要である。

解答 4.22

Train データに対する誤差が小さく、Test データで誤差が大きい場合、過学習が疑われる。逆に、両者の誤差が大きい場合は、モデルの表現力が不足している可能性がある。Train/Test の差を確認することで、モデルの汎化性能を評価できる。

解答 4.23

交差検証では、複数のデータ分割に対して性能を評価するため、より安定した評価が可能となる。

Fold ごとのばらつきが大きい場合、

- データの偏りがある
- モデルが不安定である

といった可能性が考えられる。

単一の Train/Test 分割よりも、より信頼性の高い評価が可能である。

解答 4.24

Fold 数を増やすと、より多くのデータを学習に使用できるため、評価のバイアスは減少するが、計算コストは増加する。また、Fold 数が大きすぎると（例：LOOCV）、分散が大きくなり、評価が不安定になる場合もある。一般的には 5 または 10 程度がバランスが良いとされる。

第5章 モデルアルゴリズム

演習問題

基礎問題（概念理解）

解答 5.1

「線形」とは、入力変数に対してではなく、パラメータに対して線形であることを意味する。すなわち、モデルは

$$\hat{y} = \beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p$$

のように、係数の線形結合で表現される。そのため、入力変数が x_i^2 のような非線形な関数であっても、モデル全体は線形となりうる。

解答 5.2

二乗誤差は大きな誤差に強いペナルティを与えるため、外れ値を強く意識した学習が可能である。また、微分可能であるため最適化が容易であり、解析解が求まるという利点もある。

解答 5.3

シグモイド関数は出力を 0 から 1 の範囲に制限できるため、確率として解釈可能になる。これにより、分類問題においてクラス所属確率を直接モデル化できる。

対数損失は確率モデルに基づく尤度最大化と対応しており、誤った予測に対して強いペナルティを与える。これにより確率推定として一貫性のある学習が可能になる。

解答 5.4

分割基準とは、データをどのように分割すれば目的変数がより純粋になるかを評価する指標である。分類ではジニ不純度やエントロピー、回帰では分散が使われる。ジニ不純度はクラスの混合度を表し、エントロピーは情報量の観点から不純度を評価する。それぞれの特徴は、ジニ不純度は計算が簡単で高速である一方、エントロピーは理論的な根拠が強いとされる。分割基準の選択はモデルの性能や計算効率に影響を与える。

解答 5.5

決定木はデータに完全に適合するまで分割を続けることができるため、ノイズまで学習してしまう。その結果、訓練データには適合するが未知データに対する性能が低下する。

過学習を抑制する方法としては、(1) 木の深さを制限すること、(2) 分割に必要な最小サンプル数を増やすことがある。これらの方法により、モデルの複雑さを制御し、過学習をある程度防止することができる。一方で、決定木の過学習を完全に防止することは難しいため、ランダムフォレストや勾配ブースティングなどのアンサンブル学習がよく用いられる。

解答 5.6

ランダムフォレストでは、2つのランダム性が導入されている。1つ目は、訓練データからのサンプリングであり、ブートストラップサンプリングと呼ばれる方法が用いられる。2つ目は、各分割において使用する特徴量のランダム選択であり、これにより各木が異なる特徴量を使用して分割される。これらはそれぞれの木が異なるデータと特徴量に基づいて学習されることを意味し、個々の木の予測が相互に独立になるようにする。このランダム性により、個々の木が過学習する可能性があるが、複数の木の予測を平均することで、過学習の影響が相殺され、全体として安定した予測が可能になる。

解答 5.7

勾配ブースティングは、前のモデルの誤差（残差）を次のモデルで学習し、それを逐次加算することでモデルを改善していく方法である。勾配ブースティングの「勾配」とは、損失関数に対する予測値の微分であり、誤差を減らす方向を示す量である。この勾配に基づいて次のモデルを学習する。

ランダムフォレストは複数の木を独立に学習し、その予測を平均する方法であるのに対し、勾配ブースティングは木を逐次的に学習し、前のモデルの誤差を修正する形でモデルを構築する。そのため、勾配ブースティングはより高い精度を達成できることが多いが、過学習しやすく、ハイパーパラメータの調整が重要である。

解答 5.8

線形モデルは全体に対して1つの関係式で表現するのに対し、決定木は条件分岐により局所的なルールで表現する。決定木モデルでは、特徴量空間を分割し、それぞれの領域で異なる値を持つことで、複雑な関係を段階的に近似できるため、非線形関係を表現できる。

解答 5.9

入力データに最も近い k 個の訓練データを探し、それらのラベル（または平均値）を用いて予測を行う。

kNN の弱点としては、

1. 計算コストが高い点である。予測時に全データとの距離計算が必要であるため、大規模データセットでは非効率になる。
2. 特徴量スケールに敏感である点である。特徴量のスケールが異なる場合、距離計算が偏る可能性があるため、適切な前処理（例えば標準化）が必要になる。

解答 5.10

SVM のマージンとは、クラス間の境界から最も近いデータ点までの距離であり、このマージンを最大化することで汎化性能を高める。

カーネル法の役割は、データを高次元空間に写像することで、線形分離できない問題を線形問題として扱えるようにすることである。

解答 5.11

表形式データでは特徴量数が限られ、構造も単純であることが多いため、決定木系モデルの方が効率的かつ高精度になる場合が多い。近年では、表形式データに対しても深層学習が有効なケースが増えてきているが、モデルの選択はデータの特性やタスクの要件に応じて慎重に行う必要がある。

一方で、深層学習は画像・音声・テキストなどの高次元かつ非構造的なデータに対して有効であり、大量データから複雑なパターンを学習できる。

解答 5.12

単純なモデルはバイアスが高く、複雑なモデルは分散が高い傾向がある。適切なモデルはこのトレードオフをバランスさせるものである。

実習問題：Telco Customer Churn

解答 5.13

ロジスティック回帰は単純で解釈性が高いが、非線形な関係を捉えにくい。決定木は非線形な関係を捉えやすいが、過学習しやすい。ランダムフォレストは過学習を抑制し、安定した性能を発揮する。勾配ブースティングは高精度を達成できるが、過学習しやすい。k 近傍法はシンプルだが、計算コストが高く、特徴量スケールに敏感である。サポートベクターマシンはマージン最大化により高い性能を発揮するが、カーネル選択が重要である。深層学習は大量データから複雑なパターンを学習できるが、表形式データでは必ずしも最適でない。

学習時間と予測時間は、モデルの複雑さやアルゴリズムの特性によって大きく異なる。高精度なモデルほど計算コストが高い場合があるため、実務では精度だけでなく速度も重要な判断基準となる。

解答 5.14

木の深さを増やすと訓練精度は上がるが、検証精度は低下する傾向がある。葉に含まれるサンプル数を増やすと、過学習が抑制されるが、訓練精度が低下する傾向がある。

解答 5.15

ロジスティック回帰は線形モデルであり、特徴量のスケールに敏感であるため、標準化を行うことで性能が向上する場合が多い。一方、決定木はスケールに影響されにくいいため、標準化の効果はほとんどない。

解答 5.16

class weight を調整すると少数クラスの Recall が向上するが、Precision が低下する場合がある。用途に応じたバランスが重要である。

解答 5.17

ロジスティック回帰は線形な境界を持つのに対し、決定木は非線形かつ分割ベースの境界を持つ。

解答 5.18

モデルごとに重要とされる特徴量は異なる場合がある。これはモデルの構造や相互作用の捉え方の違いによる。明らかにビジネス上重要な特徴量が低い重要度を持つ場合は、モデルの見直しや特徴量エンジニアリングの必要性があるかもしれない。

解答 5.19

訓練精度と検証精度の差が大きい場合は過学習、両方低い場合は未学習である。データ量増加による改善も確認できる。

実習問題：House Prices

解答 5.20

線形回帰は単純で解釈性が高いが、非線形な関係や特徴量間の相互作用を捉えにくい。Ridge 回帰や Lasso 回帰は正則化により過学習を抑制できるが、特徴量のスケールが重要となる。決定木は非線形な関係を捉えやすいが、過学習しやすい。ランダムフォレストは複数の木を組み合わせることで安定した性能を発揮する。勾配ブースティングは高い予測性能を得やすいが、パラメータ設定によっては過学習しやすい。k 近傍法は直感的であるが、特徴量スケールに敏感であり、予測時の計算コストも高くなりやすい。サポートベクター回帰は非線形関係を扱えるが、カーネルやパラメータの選択が重要である。深層学習は複雑な関係を表現できるが、表形式データでは必ずしも木系モデルを上回るとは限らない。

実務では、性能だけでなく、計算時間、解釈性、運用のしやすさも含めてモデルを選択する必要がある。

解答 5.21

木の深さを増やすと、訓練データに対する RMSE は小さくなる傾向がある。しかし、Validation データに対する RMSE が悪化する場合は、訓練データに過剰に適合している可能性がある。

また、葉に含まれる最小サンプル数を増やすと、木の分割が抑制されるため過学習を防ぎやすくなる。一方で、値を大きくしすぎるとモデルの表現力が不足し、Train/Validation の両方で性能が悪化する場合がある。

解答 5.22

通常の線形回帰では、スケーリングは理論上必須ではない。しかし、Ridge 回帰や Lasso 回帰のように正則化を用いる場合は、特徴量のスケールによって係数へのペナルティのかかり方が変わるため、スケーリングが重要となる。

一方、決定木は特徴量の大小関係に基づいて分割を行うため、スケーリングの影響をほとんど受けない。そのため、標準化の有無によって性能が大きく変わりにくい。

解答 5.23

SalePrice は右に裾の長い分布を持つため、そのまま学習すると高価格帯の物件が損失に強く影響する。対数変換を行うことで分布の歪みが緩和され、線形モデルでは性能が改善しやすい。

木系モデルは非線形性に強いため、対数変換なしでも一定の性能を発揮することがある。ただし、目的変数の歪みが大きい場合は、木系モデルでも対数変換により安定した予測が得られる場合がある。

解答 5.24

線形回帰は入力特徴量に対して平面的な予測面を持つ。そのため、特徴量と価格の関係を直線的・平面的に近似する。

一方、決定木回帰は特徴量空間を領域に分割し、各領域で一定の予測値を返す。そのため、階段状の予測面となり、非線形な関係を表現しやすい。ただし、分割が細かすぎると過学習しやすい。

解答 5.25

訓練 RMSE が小さく、Validation RMSE が大きい場合は過学習が疑われる。一方、訓練 RMSE と Validation RMSE の両方が大きい場合は、モデルの表現力不足や特徴量不足が考えられる。

訓練データサイズを増やしたときに Validation RMSE が改善する場合は、追加データにより性能向上が期待できる。一方、データ量を増やしても改善しない場合は、特徴量設計やモデル構造の見直しが必要となる。

解答 5.26

特徴量を増やすことで、モデルが利用できる情報は増える。しかし、ノイズの多い特徴量や目的変数と関係の弱い特徴量を加えると、過学習や推定の不安定化につながる場合がある。

特に線形モデルでは、多重共線性により係数の解釈が不安定になることがある。木系モデルでも、不要な特徴量が多いと分割候補が増え、モデルの安定性が低下する場合がある。したがって、特徴量数だけでなく、特徴量の意味や予測への寄与を確認することが重要である。

第6章 モデルの解釈とビジネス評価

演習問題

基礎問題（概念理解）

解答 6.1

モデルの性能はデータと問題設定に強く依存するためである。誤った目的変数や不適切なデータが使われている場合、どれだけモデルを改善しても本質的な精度向上は望めない。

解答 6.2

モデルは与えられた特徴量からしか学習できないためである。重要な情報が特徴量として表現されていなければ、どれだけ高度なモデルでもそれを利用することはできない。

解答 6.3

モデル解釈性とは、モデルの予測がどのような理由で行われているかを理解できることを指す。例えば、特徴量の重要度や予測に対する各特徴量の寄与を説明できることが含まれる。モデル解釈性は、モデルの予測結果を人間が理解し、信頼し、意思決定に活用するために重要である。また、誤った判断を防ぐためにも重要である。

解答 6.4

モデル精度が高くても、それがビジネス上の利益やコスト削減につながるとは限らないためである。意思決定への影響を考慮する必要がある。

解答 6.5

- 分類問題では、単純なモデルの性能追及は、例えば精度や AUC などの指標を向上させることに焦点を当てる。一方、ビジネスインパクトの評価は、例えば不正検知モデルであれば、誤検知と見逃しのコストを考慮して、どのような閾値が最適かを評価することになる。特に閾値の選択は、ビジネスインパクトに大きな影響を与えるため、単純な性能指標だけでは判断できない。
- 回帰問題では、単純なモデルの性能追及は、例えば平均二乗誤差を減らすことに焦点を当てる。一方、ビジネスインパクトの評価は、例えば売上予測モデルであれば、予測誤差がどの程度の金銭的損失につながるかを評価することになる。

解答 6.6

モデルの予測結果が実際の意思決定にどのような影響を与えるかを事前に検証できるためである。これにより導入効果を定量的に評価できる。

実習問題：Telco Customer Churn

解答 6.7

特徴量重要度から、解約に強く影響する変数を特定できる。例えば、契約種別や料金関連の変数が重要となることが多く、短期契約や高料金が解約に影響している可能性がある。モデル別に重要な特徴量が異なる場合もあるため、複数のモデルで比較することが有益である。

解答 6.8

Permutation Importance はモデル非依存であり、特徴量のシャッフルによる性能低下で重要度を測る。モデル内の重要度とは異なる結果になる場合があり、相関の影響などが理由として考えられる。

解答 6.9

SHAP 値により各特徴量の寄与を分解できる。例えば、契約期間が短く、料金が高いことが解約確率を押し上げているなどの解釈が可能である。

解答 6.10

PDP により特徴量と予測値の関係を可視化できる。料金がある閾値を超えると急激に解約確率が上がるなど、非線形な関係が確認される場合がある。

解答 6.11

LIME は局所的な線形近似により説明を行うのに対し、SHAP はゲーム理論に基づく一貫した寄与分解を行う。説明の安定性や一貫性に違いがある。

解答 6.12

期待利益は以下で計算される：

$$\text{Profit} = \text{成功数} \times 5000 - \text{対象人数} \times 500$$

成功数は実際に解約を防げた人数に依存するため、モデルの Recall が重要となる。

解答 6.13

threshold を下げると対象人数が増えコストが増加するが、成功数も増える。利益最大となる点を探索することで最適な threshold を決定できる。モデルの性能指標と利益の関係は、特に Recall が高いモデルが利益を最大化する傾向があることが多い。

解答 6.14

全員に施策を行うとコストが過大となる。モデルにより対象を絞ることで ROI が向上する。

解答 6.15

短期契約や高料金が解約に影響している場合、長期契約割引や料金プラン見直しなどの施策が考えられる。このように、単純な確率値を利用するだけでなく、モデルから得られた知見を基に、具体的な施策を提案することが重要である。

解答 6.16

予測誤差が大きい場合、誤った施策対象の選定や見逃しが発生し、利益が減少する可能性がある。モデルの性能指標を確認し、誤差の大きさとビジネスインパクトの関係を考察することが重要である。

実習問題：House Prices

解答 6.17

特徴量重要度から、住宅価格に強く影響する変数を特定できる。例えば、OverallQual、GrLivArea、GarageCars、TotalBsmtSF、YearBuilt などが重要となることが多い。

線形モデルでは、係数の符号から価格を押し上げる方向か下げる方向かを解釈できる。一方、ランダムフォレストや勾配ブースティングの重要度は、主に分割における貢献度を表すため、特徴量が価格を上げるのか下げるのかまでは直接分らない。そのため、特徴量重要度だけでなく、PDP や SHAP などと組み合わせて解釈することが重要である。

解答 6.18

Permutation Importance は、ある特徴量をシャッフルしたときにモデル性能がどれだけ低下するかで重要度を測る。モデルに依存しにくい方法であり、線形モデル、ランダムフォレスト、勾配ブースティングなどに共通して適用できる。

通常の特徴量重要度と異なる結果になる理由として、特徴量間の相関がある。例えば、GarageCars と GarageArea のように似た情報を持つ特徴量がある場合、片方をシャッフルしてももう片方が情報を補うため、重要度が低く見えることがある。

解答 6.19

SHAP 値により、各特徴量が予測価格をどの程度押し上げたか、または押し下げたかを分解できる。例えば、OverallQual が高い、GrLivArea が広い、築年数が新しいといった特徴は、価格を押し上げる方向に寄与することが多い。

一方で、立地条件が相対的に低評価の地域である、地下室やガレージがない、築年数が古いなどの特徴は、価格を押し下げる方向に寄与する可能性がある。個別物件の説明では、単に予測価格を見るだけでなく、どの特徴がその価格を作っているかを確認することが重要である。

解答 6.20

PDP により、他の特徴量の影響を平均化した上で、GrLivArea と予測価格の関係を可視化できる。

一般に、居住面積が大きいほど予測価格は上昇する傾向がある。ただし、面積が大きくなるほど価格上昇幅が一定でない場合や、ある範囲を超えると上昇が緩やかになる場合がある。このような形状は、住宅価格と面積の関係が単純な線形関係ではないことを示している。

解答 6.21

LIME は、説明したい個別サンプルの周辺でモデルを局所的に近似し、その近似モデルを用いて予測理由を説明する方法である。一方、SHAP は各特徴量の寄与を一貫したルールで分解する方法である。

LIME は直感的で使いやすいが、近傍サンプルの生成方法やランダム性によって説明が変わる場合がある。SHAP は説明の一貫性が高い一方で、モデルやデータサイズによって計算コストが高くなる場合がある。

解答 6.22

予測価格が実際の適正価格より高すぎる場合、販売価格が過大になり、売却までの期間が長くなる可能性がある。その結果、販売機会の逸失、広告費や保有コストの増加、価格改定によるブランド低下などが発生する。

一方、予測価格が低すぎる場合、本来より安く販売してしまい、直接的な収益機会を失う。したがって、住宅価格予測では単に平均誤差を小さくするだけでなく、誤差の方向とビジネス上の損失を考慮する必要がある。

解答 6.23

次のような手順でビジネス損失を計算し、モデルを比較することができる。

1. 検証データに対して複数モデルの予測値 $\hat{y}$ を作成する。
2. 各物件について、過大評価額 $\max(\hat{y} - y, 0)$ と過小評価額 $\max(y - \hat{y}, 0)$ を計算する。
3. C_{over} と C_{under} を設定し、物件ごとの Business Loss を計算する。

4. 全物件の平均 Business Loss をモデルごとに比較する。
5. RMSE や MAE で良いモデルと、Business Loss で良いモデルが一致するか確認する。

この損失関数は、予測価格が実際価格より高い場合と低い場合で異なる損失を与える。過大評価のコストが大きい場合は C_{over} を大きくし、過小評価のコストが大きい場合は C_{under} を大きくする。

RMSE や MAE が同程度のモデルであっても、誤差の方向が異なればビジネス損失は変わる。そのため、住宅価格予測では統計的な誤差指標だけでなく、意思決定上の損失を定義して比較することが重要である。

解答 6.24

予測価格より低めに設定すると、売れ残りリスクは下がるが、安値販売による損失が増える可能性がある。一方、予測価格より高めに設定すると、収益機会は増える可能性があるが、売れ残りリスクが高まる。

最適な安全係数は、過大評価と過小評価のどちらのコストを重く見るかによって変わる。例えば、早期売却を重視する場合は低めの価格設定が望ましい場合があり、利益率を重視する場合は高めの価格設定が許容される場合もある。

解答 6.25

具体的に平均価格や中央値を基準価格として設定し、その価格と実際の価格との差からビジネス損失を計算する。平均価格や中央値を用いる方法は単純であるが、個別物件の品質、面積、立地、築年数などを反映できない。そのため、高品質な物件を過小評価したり、低品質な物件を過大評価したりする可能性が高い。

モデルを用いることで、物件ごとの特徴を考慮した価格設定が可能となり、統計的な誤差だけでなくビジネス損失も削減できる可能性がある。ただし、モデルの予測にも誤差があるため、過信せず、査定担当者の判断や市場状況と組み合わせる必要がある。

解答 6.26

高価格帯では物件数が少ないため、モデルが十分に学習できず誤差が大きくなる場合がある。また、高価格帯の誤差は金額ベースで大きくなりやすく、Business Loss への影響も大きい。特に高価格帯で過小評価が多い場合、本来得られたはずの収益を逃している可能性がある。一方、高価格帯で過大評価が多い場合、売れ残りや販売期間の長期化につながる可能性がある。

低価格帯では、物件の差が価格に反映されにくい場合や、外れ値の影響で誤差が発生する場合がある。また、低価格帯で RMSE が大きい場合は、一部の外れ値が評価を悪化させている可能性があるため、MAE と RMSE を比較して確認することが重要である。

改善方針としては、以下が考えられる。

- 高価格帯で誤差が大きい場合：高価格帯に特化した特徴量を追加する。
- 高価格帯のデータ数が少ない場合：価格帯別にモデルを分けるのではなく、対数変換や重み付き学習を検討する。

- 特定価格帯で過大評価が多い場合：予測値に補正係数をかける、または価格帯別にキャリブレーションする。
- 特定価格帯で過小評価が多い場合：その価格帯の重要特徴量や外れ値を再確認する。
- 全体的に高価格帯の誤差が大きい場合：RMSE だけでなく、価格帯別の Business Loss を評価指標に加える。

この演習の目的は、平均的な RMSE や MAE だけでは見えないモデルの弱点を把握することである。同じ平均誤差でも、どの価格帯で誤差が発生しているかによって、ビジネス上の意味は大きく異なる。

解答 6.27

各物件について予測誤差、および誤差分布の平均と標準偏差を計算する。

$$e_i = \hat{y}_i - y_i$$

$$\mu_e = \frac{1}{n} \sum_{i=1}^n e_i$$

$$\sigma_e = \sqrt{\frac{1}{n} \sum_{i=1}^n (e_i - \mu_e)^2}$$

これにより、典型的な誤差の大きさを把握できる。例えば、誤差が正規分布に近いと仮定するなら、 $\mu_e \pm \sigma_e$ は比較的良好に起こる誤差範囲を表し、 $\mu_e \pm 2\sigma_e$ は大きめの誤差が発生した場合の影響を表す。

ただし、住宅価格の誤差分布は外れ値や歪みを含むことがあるため、正規分布を仮定した代表点だけでなく、5%点、50%点、95%点などの分位点も確認することが望ましい。

次に、誤差 e に対するビジネス損失関数

$$L(e) = C_{\text{over}} \cdot \max(e, 0) + C_{\text{under}} \cdot \max(-e, 0)$$

を定義する。この式では、 $e > 0$ の場合は過大評価による損失として $C_{\text{over}}e$ が発生する。一方、 $e < 0$ の場合は過小評価による損失として $C_{\text{under}}(-e)$ が発生する。

したがって、誤差分布の代表点をこの関数に代入することで、代表的な予測誤差がどの程度のビジネス損失に変換されるかを確認できる。

この分析により、平均的な RMSE や MAE だけでは分らない、誤差の方向別のビジネス影響を確認できる。特に、 C_{over} と C_{under} が異なる場合、同じ大きさの誤差であっても、過大評価と過小評価で損失の意味が異なる。

例えば、売れ残りを避けたいビジネスでは C_{over} を大きく設定する。この場合、過大評価側の誤差が特に重要になる。一方、安値販売による収益逸失を避けたい場合は C_{under} を大きく設定する。この場合、過小評価側の誤差が重要になる。

したがって、この演習では、予測誤差分布を確認した上で、その代表的な誤差がビジネスインパクト関数を通じてどの程度の損失に変換されるかを評価することが重要である。

第7章 本番運用

演習問題

基礎問題（概念理解）

解答 7.1

代表的な問題として以下が挙げられる。

- 前処理の不一致：学習時と同じ前処理が再現されないと入力分布が変わり、予測精度が低下する。
- データ取得の違い：本番では同じデータが取得できない可能性があり、特徴量が再現できない。
- 処理時間の制約：分析では許容された処理時間が、本番のリアルタイム処理では許容されない。

解答 7.2

バッチ処理は一定期間のデータをまとめて処理する方式であり、大量データ処理に適する。例：日次の需要予測。

リアルタイム処理はリクエストごとに即時推論を行う方式であり、即時性が求められる場面に適する。例：与信審査。

解答 7.3

それぞれの環境の役割は以下の通りである。

- 分析環境：データ探索やモデル構築など、柔軟な試行錯誤を目的とする。
- 開発環境：分析で得られた知見をもとに、コードの品質を高めるための環境。
- 検証環境：本番環境に近い条件で動作確認を行う環境。
- 本番環境：安定性・再現性が求められる環境で、実際の業務にモデルを適用する場所。

とくに分析環境は柔軟な試行錯誤を目的とするが、本番環境は安定性・再現性が求められる。これらを分離しないと、未検証コードの本番投入や、再現性の欠如による不具合が発生する。

解答 7.4

- ・意思決定ルール：モデルのスコアに応じた業務分岐を定義することで、モデルの予測を具体的な行動に結びつける。
- ・責任分担：モデルと人間の役割を明確にすることで、運用の混乱を防ぎ、適切な対応が取れるようにする。

解答 7.5

- ・入力分布の変化 (covariate shift)：モデルに入力されるデータの分布が変わる現象。目的変数との関係は変わらないため、モデルへの即時影響は限定的であるが、予測性能が低下する可能性がある。対処方針は、入力分布の変化を検知し、必要に応じてモデルを再学習すること。
- ・入力と目的変数の関係の変化 (concept drift)：モデルが学習した規則そのものが変わる現象。モデルの予測性能が大幅に低下する可能性がある。対処方針は、関係の変化を検知し、モデルを再構築すること。

解答 7.6

- ・入力データ：分布や欠損を監視し、データの健全性を確認する。
- ・モデル出力：予測値の分布を監視し、モデルの挙動を確認する。
- ・業務成果：KPI を監視し、モデルの実務価値を確認する。

解答 7.7

与信モデルのように、目的変数が数か月後に確定する場合、即座に精度を測定できない。

ラベルが遅れて得られる場合は、入力分布や出力分布、業務 KPI などの代替指標を監視し、異常の兆候を早期に捉える。

実習問題：Telco Customer Churn

解答 7.8

利用目的は解約可能性の高い顧客を早期に特定し、リテンション施策の対象を選定することである。利用者はマーケティング部門、CRM 担当、コールセンター管理者などが想定される。利用タイミングは月次または週次のバッチスコアリングが基本となる。出力は顧客 ID、解約確率、リスクランク、推奨アクションなどであり、後続アクションとしてキャンペーン配信、担当者フォロー、契約プラン見直しなどが考えられる。

解答 7.9

一般にはバッチ推論が適している。解約防止施策は秒単位で判断する必要があるケースは少なく、月次料金、契約状態、利用状況などのデータ更新も日次または月次で十分な場合が多い。また、キャンペーン配信やコールリスト作成も一定期間ごとに実行されるため、バッチ処理の方が運用しやすい。ただし、Web やアプリ上で解約手続き画面に遷移した瞬間に引き止め施策を出すような用途では、リアルタイム推論を検討する価値がある。

解答 7.10

本番データでは、訓練時と同じカラムが存在するか、データ型が一致しているかを確認する必要がある。欠損値については、必須項目の欠損率や特定カラムの欠損有無を確認する。カテゴリ変数では、訓練時に存在しなかった未知カテゴリが出現していないかを確認する。数値変数では、**tenure** が負でないか、**MonthlyCharges** や **TotalCharges** が異常に大きくないかを確認する。また、同一顧客 ID の重複や、顧客マスタに存在しない ID が含まれていないかも確認すべきである。

解答 7.11

未知カテゴリに対しては、事前に **Other** や **Unknown** にまとめる方針を用意しておくことが望ましい。One-hot encoding を用いる場合、未知カテゴリでエラーにならないように `handle_unknown='ignore'` のような設定を行う。同時に未知カテゴリの値を含む場合、モデルとしてどのような予測を出すべきかを定義しておくことも重要である。

ただし、未知カテゴリの出現頻度が高い場合は、データ仕様や業務プロセスが変化している可能性があるため、単なる例外処理ではなくモニタリング対象とする必要がある。

解答 7.12

負の料金は通常の業務上は不自然であるため、データエラーとして扱うべきである。処理方針としては、当該レコードをスコアリング対象から除外する、欠損扱いにして補完する、または業務システムに差し戻すことが考えられる。極端に大きな値については、上限値でクリッピングする方法もあるが、実際に高額契約が存在する可能性もあるため、業務ルールに基づいて判断する必要がある。重要なのは、例外処理の内容をログに残し、後から件数や影響を確認できるようにすることである。

解答 7.13

TotalCharges は契約期間や月額料金と関係するため、全体平均で補完すると不自然な値になる可能性がある。例えば新規顧客では累計料金が小さくなるはずであり、長期契約顧客では大きくなるはずである。より望ましい方針として、**tenure** と **MonthlyCharges** から概算値を作る、または欠損フラグを追加した上でモデルに投入する方法が考えられる。

一方で、**TotalCharges** が欠損すること自体が業務やシステムの問題を示している可能性もあるため、欠損状況をモニタリングし、必要に応じて業務プロセスの見直しやシステム改修を検討することも重要である。

解答 7.14

バッチ処理を想定しているため、各システムから定期的にデータを収集し、DWH またはデータマートに統合する構成が望ましい。顧客 ID をキーとして、顧客属性、利用状況、支払履歴、キャンペーン履歴を結合し、スコアリング用の特徴量テーブルを作成する。その後、バッチ処理でモデルを実行し、スコア結果を CRM やキャンペーン管理システムに返す。この構成により、データ加工、モデル推論、施策実行を分離でき、再現性と保守性が高まる。

リアルタイム処理を検討する場合は、API やストリーム処理を用いて、必要なデータをリアルタイムに取得し、即時にスコアリングする構成も考えられる。

解答 7.15

ミニマム実装では、CSV または DWH から月次でデータを抽出し、Python スクリプトで前処理とスコアリングを行い、結果を CSV として CRM 担当者に渡す構成が考えられる。この構成は短期間で導入しやすく、PoC から初期運用に適している。一方で、手作業が残りがやすく、データ品質チェック、エラー通知、履歴管理、権限管理が弱くなる。したがって、継続運用する場合はワークフロー管理、ログ管理、監視、モデル管理を段階的に追加する必要がある。

解答 7.16

拡張性を考える場合、データ取り込み、特徴量生成、推論、結果配信、モニタリングをパイプライン化することが望ましい。DWH や Feature Store に特徴量を蓄積し、ワークフロー管理ツールで定期実行する。モデル、前処理、パラメータはバージョン管理し、推論結果と入力データのスナップショットを保存する。さらに、CRM やキャンペーン管理システムと連携し、施策結果を再び分析基盤に戻すことで、モデル改善や効果検証につなげることができる。

解答 7.17

入力データについては、レコード件数、欠損率、未知カテゴリ出現率、数値変数の平均・分位点、カテゴリ比率などを監視する。頻度は、月次スコアリングであれば毎回の実行時、重要指標は週次または月次レビューで確認する。一次監視はデータエンジニアまたは運用担当が行い、分布変化や業務影響が疑われる場合はデータサイエンティストや業務担当者が確認する。

解答 7.18

出力結果については、予測確率の平均、分位点、リスクランク別人数、施策対象者数、前回実行との差分などを監視する。例えば、突然高リスク顧客が急増した場合、実際に解約リスクが高まっている可能性もあるが、入力データや前処理に異常が発生している可能性もある。したがって、出力結果だけでなく入力データの変化と合わせて確認する必要がある。

解答 7.19

性能指標としては、AUC、Precision、Recall、F1-score、Calibration、施策対象群の実解約率などが考えられる。ただし、解約は将来発生するイベントであるため、スコアリング直後には正解ラベルが得られない。例えば月初にスコアリングし、翌月または翌々月の解約を観測して初めて性能評価が可能となる。そのため、入力・出力のモニタリングは即時に行い、性能モニタリングはラベル確定後に行う必要がある。

解答 7.20

閾値は業務上の許容範囲と過去変動をもとに設定する。例として、欠損率が前回より 5 ポイント以上増加した場合、未知カテゴリ比率が 1%を超えた場合、主要カテゴリ比率が 10 ポイント以上変化した場合、予測確率の平均が過去 3 か月平均から大きく外れた場合などを警告対象とする。ただし、固定閾値だけでは誤検知や見逃しが発生するため、過去の自然変動幅を用いた管理限界や、PSI などの分布変化指標を併用するとよい。

解答 7.21

まず、入力データの件数、欠損率、未知カテゴリ、数値変数の分布が変化していないか確認する。次に、前処理やスコアリングコードのバージョンが変わっていないか確認する。その上で、料金改定、キャンペーン終了、競合施策、障害発生などの業務イベントがなかったかを確認する。実解約率がまだ観測できない段階では、モデル異常とビジネス環境変化の両方を仮説として扱う必要がある。

解答 7.22

定期再学習は、例えば四半期ごとや半年ごとに最新データを用いてモデルを更新する方法である。一方、トリガーベース再学習は、性能低下、データ分布変化、サービス体系変更、料金改定などが発生した場合に実行する。再学習の条件として、AUC が一定以上低下した場合、Recall が目標値を下回った場合、PSI が高い値を示した場合、主要特徴量の分布が大きく変化した場合などが考えられる。

解答 7.23

これらを保存することで、後からモデルの性能評価、施策効果の検証、業務判断の監査が可能となる。モデルスコアだけでは、実際にどの顧客へ施策を実施したか、どの施策が効いたかを判断できない。また、施策対象者だけが特別な対応を受けるため、単純な解約率比較では施策効果とモデル効果が混ざる。したがって、スコア、意思決定、施策、結果を一連の履歴として残すことが重要である。

実習問題：House Prices

解答 7.24

利用目的は、住宅価格の査定支援や販売価格設定支援である。利用者としては、不動産査定担当者、営業担当者、投資担当者などが想定される。

利用タイミングとしては、

- 査定依頼時
- 販売価格設定時
- 投資判断時

などが考えられる。

出力結果としては、

- 予測価格
- 価格レンジ
- 信頼区間
- 主要特徴量の寄与

などが考えられる。

後続アクションとしては、

- 販売価格の決定
- 値下げ判断
- 投資判断
- 人手査定へのエスカレーション

などがある。

解答 7.25

一般にはリアルタイム推論が望ましい場合が多い。査定担当者が物件情報を入力した際、その場で参考価格を表示したいケースが多いためである。

一方で、全物件の価格見直しや市場分析を目的とする場合は、日次または週次バッチ処理も有効である。

また、地価や市場価格は秒単位では変化しないため、特徴量更新自体はバッチ処理で十分な場合も多い。したがって、

- 査定支援：リアルタイム
- 市場分析：バッチ

のように使い分ける構成が考えられる。

解答 7.26

本番データでは、

- 訓練時と同じカラムが存在するか
- データ型が一致しているか

を確認する必要がある。

欠損については、

- 必須項目（面積、築年数、立地など）の欠損
- 欠損率の急増

を確認する。

カテゴリ変数では、

- 未知の地域名
- 未知の住宅タイプ

などを確認する。

数値変数では、

- 面積が負
- 築年数が未来
- 部屋数が極端

などの異常値を確認する必要がある。

また、超高級物件や特殊物件など、訓練データから大きく外れた物件については、モデルの適用対象外とする判断も必要である。

解答 7.27

未知地域については、

- Unknown カテゴリとして扱う
- 地理情報から近隣地域へマッピングする
- 人手査定へ回す

などの方法が考えられる。

ただし、未知地域の出現は、

- 新規開発地域
- データ仕様変更
- 入力ミス

などを示している可能性もあるため、頻度をモニタリングする必要がある。

解答 7.28

極端に大きい値は、

- 入力ミス
- 単位変換ミス
- 実際の超大型物件

などの可能性がある。

処理方針としては、

- 上限値でクリッピングする
- 人手確認へ回す
- モデル適用対象外とする

などが考えられる。

特に高価格帯・大型物件は、訓練データ数が少なく予測誤差が大きくなりやすいため、単純な自動査定のみで価格決定しない運用が望ましい。

解答 7.29

各システムから定期的にデータを収集し、DWH または特徴量テーブルに統合する構成が望ましい。

例えば、

- 物件マスタ
- 地理情報
- 過去売買履歴
- 周辺施設情報

を物件 ID や位置情報で結合し、推論用特徴量を生成する。

リアルタイム査定では、入力物件情報に対して API 経由で特徴量を取得し、即時に推論する構成も考えられる。

解答 7.30

ミニマム実装では、査定担当者が CSV または Web フォームへ物件情報を入力し、Python スクリプトまたは API で価格予測を行う構成が考えられる。

この構成は導入が容易で PoC 向きである。一方で、

- データ品質管理
- モデルバージョン管理
- 査定履歴管理
- 監査対応

などが弱く、継続運用には不十分となる可能性がある。

解答 7.31

拡張性を考える場合、

- 特徴量生成
- 推論
- ログ保存
- モデル管理
- モニタリング

を分離したパイプライン構成が望ましい。モデルや前処理はバージョン管理し、査定結果と入力特徴量を保存することで、後から査定根拠を追跡できるようにする必要がある。また、市場価格変動への対応のため、再学習基盤やデータ更新基盤も重要となる。

解答 7.32

入力データについては、

- レコード件数
- 欠損率
- 数値分布
- 地域別件数
- 高価格帯割合

などを監視する。

また、

- 新規地域の出現
- 異常面積
- 築年数異常

なども確認する必要がある。

一次監視は運用担当またはデータエンジニアが行い、市場構造変化が疑われる場合はデータサイエンティストや業務担当者が確認する。

解答 7.33

出力結果については、

- 予測価格平均
- 分位点
- 高価格帯割合
- 地域別価格分布

- 人手査定との差

などを監視する。

突然価格分布が変化した場合、

- 市場変化
- 入力異常
- モデル異常

などの可能性がある。

そのため、入力分布と合わせて確認する必要がある。

解答 7.34

性能指標としては、

- RMSE
- MAE
- 価格帯別誤差
- 過大評価率
- 過小評価率
- Business Loss

などが考えられる。

ただし、実際の売買価格が確定するまでには時間がかかるため、査定直後には正解ラベルが得られない。そのため、

- 入出力監視：即時
- 性能評価：売買成立後

という形で時間差が発生する。

解答 7.35

住宅市場は金利、景気、地域開発などの影響を受けるため、価格分布自体が時間とともに変化する。

そのため、

- 価格分布
- 地域別価格
- 高価格帯割合
- 予測誤差分布

などを継続的に監視する必要がある。

また、PSI や分布比較指標を用いて、訓練時との分布差を定量化することも有効である。

解答 7.36

定期再学習では、例えば四半期ごとや半年ごとに最新データで再学習する。

一方、トリガーベース再学習では、

- RMSE 悪化
- Business Loss 増加
- 市場価格急変
- 大規模金利変更

などを契機に再学習を行う。

特に不動産市場は景気や金利変化の影響を強く受けるため、単純な定期再学習だけでは不十分な場合がある。

第8章 モデル改善戦略

演習問題

基礎問題（概念理解）

解答 8.1

誤差分析を行う目的は、モデルが「どこで」「なぜ」失敗しているかを把握し、改善の方向性を定めることである。

例えば、

- 高価格帯だけ大きく外している
- 特定地域だけ誤差が大きい
- 新規顧客だけ予測が不安定

などが分かれば、不足している情報や特徴量を推測できる。

一方、誤差分析を行わずに、

- 深いモデルへ変更する
- 特徴量を大量追加する
- ハイパーパラメータ探索を大規模実施する

などを行っても、改善理由が分からず、計算コストだけ増える可能性がある。例えば、単にデータ不足が原因である場合、モデルを複雑化しても効果は限定的である。

誤差分析は、「どの改善を優先すべきか」を判断するための出発点である。

解答 8.2

全体指標は平均的な性能しか示さないため、特定条件下での重大な失敗を見逃す可能性がある。

例えば住宅価格予測では、全体 RMSE が良好であっても、高価格帯だけ大きな誤差が発生している可能性がある。この場合、平均的には性能が良く見えても、実際には高額物件の査定で大きな損失が発生する可能性がある。

また、解約予測では、全体 Accuracy が高くても、実際には解約顧客をほとんど検知できていない場合がある。これはクラス不均衡によって、多数派クラスだけを予測しても高 Accuracy になるためである。

さらに、

- 特定地域

- ・ 特定年齢層
- ・ 新規顧客

など、特定セグメントのみ性能が悪化している場合もある。また、一部の巨大誤差がビジネス損失を支配しているケースもある。

したがって、全体指標だけでなく、条件別誤差、誤差分布、価格帯別誤差、ビジネス損失なども併せて確認する必要がある。

解答 8.3

条件別に誤差を分解するとは、特定の特微量や条件ごとにデータを分割し、それぞれの領域で誤差を評価することである。

例えば、

- ・ 高価格帯 / 低価格帯
- ・ 長期契約 / 短期契約
- ・ 地域別
- ・ 新規顧客 / 既存顧客

などで分解できる。これにより、

- ・ どの領域で性能が悪いか
- ・ どの領域で過学習しているか
- ・ どの領域に追加情報が必要か

を把握できる。

例えば、高価格帯だけ誤差が大きい場合、高価格物件に特有の特微量が不足している可能性がある。

解答 8.4

特定領域で誤差が大きい場合、複数の原因が考えられる。

- ・ まず、その領域のデータ数が少ない場合、モデルが十分に学習できていない可能性がある。この場合、追加データ収集やデータ拡張が有効となる。
- ・ 次に、その領域に必要な特微量が不足している可能性がある。例えば住宅価格予測で、高級住宅特有の設備情報が存在しない場合、高価格帯で誤差が増加する可能性がある。
- ・ また、モデル構造が問題となる場合もある。例えば線形モデルでは、非線形関係を十分に表現できない可能性がある。
- ・ さらに、外れ値やデータ品質問題が原因である場合もある。例えば入力ミスや異常物件が存在すると、一部領域で巨大誤差が発生する。

このように、誤差分析では「誤差が大きい」という事実だけでなく、その背後にある原因を仮説として整理することが重要である。

解答 8.5

改善施策は、期待性能だけでなく、実装コストや保守性も含めて判断する必要がある。

一般に、特徴量改善は比較的效果が大きく、モデルを大きく複雑化しなくても性能改善につながるが多い。また、特定セグメントで誤差が集中している場合は、その領域の追加データ収集が高い効果を持つ可能性がある。

一方、大規模なハイパーパラメータ探索は、計算コストが高い割に改善幅が小さい場合もある。さらに、複雑なモデルへの変更は、性能向上につながる可能性がある一方で、

- 解釈性低下
- 学習時間増加
- 運用複雑化

などの問題もある。

したがって、まずは誤差分析を基に、原因に直接対応する改善を優先することが重要である。

解答 8.6

モデルは入力された特徴量からしか情報を得られないため、特徴量が不足している場合、どれだけ複雑なモデルを使っても性能改善には限界がある。例えば住宅価格予測で、立地情報が存在しない場合、高性能モデルを使っても価格を正しく予測することは難しい。

モデル改善は、既存情報の利用方法を改善するアプローチである。一方、データ追加は学習事例そのものを増やす方法である。特徴量改善は、既存データから新しい意味を持つ情報を作り出すことであり、実務では非常に大きな性能改善につながる場合が多い。例えば、

- 比率
- 差分
- 集約値
- 時系列特徴

などは、単純な元変数より有効な場合がある。

解答 8.7

特徴量設計では、モデルが学習しやすい形で情報を表現することが重要である。

比率特徴量の例としては、

- 負債 / 年収
- 単価 = 価格 / 面積

などがある。

差分特徴量としては、

- 前月との差

- 平均からの乖離

などがある。

集約特徴量としては、

- 顧客ごとの平均購入額
- 地域ごとの平均価格

などがある。

相互作用特徴量としては、

- 年齢 × 年収
- 面積 × 地域

などがある。機械的に全ての組み合わせを作ることできるが、ドメイン知識を活用して意味のある組み合わせを設計することが重要である。

これらにより、単独特徴量では表現しにくい関係をモデルが捉えやすくなる。

解答 8.8

特徴量を増やすことで情報量は増えるが、同時にノイズも増える可能性がある。不要な特徴量が多い場合、モデルは偶然のパターンまで学習してしまい、過学習を引き起こす可能性がある。また、特徴量数増加により、

- 学習時間増加
- 推論時間増加
- メモリ消費増加

などの問題も発生する。さらに、大量特徴量はモデル解釈を難しくする。特に相関の高い特徴量が多い場合、どの特徴量が本当に重要なのか判断しにくくなる。

したがって、特徴量追加は「多ければ良い」わけではなく、意味と有効性を確認しながら行う必要がある。

解答 8.9

特徴量選択の目的は、不要または有害な特徴量を除去し、モデルを安定化することである。不要特徴量を除去することで、ノイズが減少し、過学習を抑制できる場合がある。また、少数特徴量で高性能を実現できれば、解釈性も向上する。さらに、本番運用では、特徴量数が少ないほど、

- データ収集
- 前処理
- システム連携

が簡単になる。

そのため、特徴量選択は単なる性能改善だけでなく、運用面でも重要な意味を持つ。

解答 8.10

相関の高い特徴量が多い場合、線形モデルでは多重共線性が発生し、係数が不安定になる可能性がある。例えば、片方の特徴量を少し変更しただけで、係数が大きく変動する場合がある。また、重要度解釈も難しくなる。

一方、木モデルでは、関連特徴量のうち一部のみが優先的に利用されることがある。その結果、重要度が分散したり、一方の特徴量だけが重要と判定される場合がある。

したがって、関連特徴量が存在する場合は、

- 次元削減
- 特徴量統合
- ドメイン知識による整理

などを検討する必要がある。

解答 8.11

ハイパーパラメータチューニングでは、検証データに対して性能比較を繰り返しながら、最も良いパラメータを選択する。しかし、大量の組み合わせを試行すると、偶然その検証データに適合したパラメータが選ばれる可能性がある。これは、「モデルが検証データへ過適合している」状態である。例えば、1000 通りのパラメータを試行すると、本当に汎化性能が高いわけではなく、偶然その検証データで良いスコアが出ただけの組み合わせが選ばれる可能性がある。また、探索空間が大きいほど、偶然良い結果を出す組み合わせが現れやすくなる。そのため、

- Nested CV
- 別テストデータ
- 探索範囲制限

などが重要となる。

解答 8.12

グリッドサーチは、事前に定義した全てのパラメータ組み合わせを網羅的に探索する方法である。一方、ランダムサーチは、パラメータ空間からランダムにサンプリングしながら探索する方法である。

グリッドサーチは実装が単純で再現性も高いが、パラメータ数が増えると組み合わせ数が爆発的に増加する。例えば、10 通りの値を持つパラメータが 5 個ある場合、

$$10^5 = 100000$$

通りを試行する必要がある。

一方、ランダムサーチでは、重要でないパラメータに大量試行を浪費しにくいため、高次元探索で効率が良い場合がある。特に、「一部のハイパーパラメータだけが性能に強く影響する」ケースでは、ランダムサーチが有効となる。

解答 8.13

ベイズ最適化は、過去の評価結果を利用して、「次にどのパラメータを試すべきか」を確率的に決定する方法である。例えば、既に良い結果が得られている領域の近傍を優先的に探索することで、効率的に最適解へ近づこうとする。ここで、「活用」とは、既に良さそうだと分かっている領域を重点的に試すことである。一方、「探索」とは、まだ試していない未知領域を調査することである。

活用だけを行うと局所最適へ閉じ込められる可能性がある。一方、探索だけを行うと効率が悪くなる。ベイズ最適化は、この探索と活用のバランスを取りながら、少ない試行回数で高性能パラメータを見つけることを目的としている。

解答 8.14

アンサンブルは、複数モデルの予測を組み合わせることで、個々のモデルの弱点を補う方法である。例えば、あるモデルが失敗するケースを、別モデルが正しく予測できる場合、平均化によって全体性能を向上できる。特に、各モデルの誤りが相関していない場合、アンサンブル効果が高くなる。

例えば、

- ・ 線形モデル
- ・ 木モデル
- ・ ニューラルネットワーク

など、異なる性質のモデルを組み合わせることで、異なるパターンを捉えられる場合がある。一方、全モデルが同じ失敗をする場合、アンサンブル効果は限定的となる。

解答 8.15

バギングは、複数モデルを独立に学習し、その予測を平均する方法である。代表例はランダムフォレストである。バギングでは、個々のモデルの分散を減らすことで、過学習を抑制する。

一方、ブースティングは、前段モデルの誤差を次段モデルで補正する形で、逐次的に学習を進める。代表例は Gradient Boosting や XGBoost である。ブースティングでは、「どこで失敗したか」を重点的に学習するため、高い性能を得やすい。ただし、過学習しやすく、ハイパーパラメータ調整も重要となる。

解答 8.16

アンサンブルは、複数モデルを組み合わせることで、単一モデルより高精度になりやすい。一方で、

- ・ 推論時間増加
- ・ メモリ消費増加
- ・ 実装複雑化

などの問題がある。また、多数モデルの組み合わせでは、「なぜその予測になったか」を説明しにくくなる場合がある。例えば、金融審査や医療では、解釈性要求が高いため、単純モデルが優先される場合もある。

したがって、実務では単純に精度だけでなく、運用制約も含めてモデルを選択する必要がある。

解答 8.17

データ追加により、モデルはより一般的なパターンを学習できるようになる。その結果、過学習が抑制され、汎化性能が向上する可能性がある。

ただし、単純にランダムデータを増やすだけでは、改善効果が限定的な場合もある。例えば、高価格帯で誤差が集中している場合、高価格帯データを重点的に追加の方が効果的である。つまり、誤差分析に基づいて、「どの領域のデータを増やすべきか」を判断することが重要である。

解答 8.18

外れ値は、一部モデルに大きな影響を与える。特に線形回帰では、二乗誤差最小化を行うため、巨大誤差へ強く引っ張られる。その結果、全体傾向より、少数外れ値への適合を優先してしまう場合がある。また、RMSE も二乗誤差ベースであるため、少数の巨大誤差に強く影響される。

一方、木モデルは分割ベースであるため、線形モデルほど外れ値へ敏感ではない場合がある。ただし、極端外れ値は木分割自体を歪める可能性もあるため、完全に無影響ではない。

解答 8.19

誤差が特定条件に集中せず、ランダムに発生している場合、モデルが既に主要パターンを学習済みである可能性がある。この場合、現在の特徴量では説明できない情報が残っている可能性がある。

例えば、

- ・ ノイズ要因
- ・ 未観測変数
- ・ 人間判断要素

などが存在する場合、モデル改善には限界がある。

改善方針としては、

- ・ 新規データ取得
- ・ 新特徴量追加
- ・ 外部データ利用

などが考えられる。

一方、単純なモデル複雑化だけでは、改善効果が小さい場合も多い。

解答 8.20

モデル改善では、単純に性能改善量だけでなく、実装・運用コストも含めて判断する必要がある。例えば、0.1%の精度改善のために、推論時間が10倍になる場合、実務上は望ましくない場合がある。

また、大量特徴量追加や巨大アンサンブルは、保守性を悪化させる可能性もある。そのため、

- 効果が大きい
- 実装が容易
- 保守しやすい

施策を優先することが重要である。

一般に、誤差分析から直接導ける改善は、高い費用対効果を持つことが多い。

解答 8.21

実務では、データや環境が継続的に変化するため、一度作成したモデルが永久に最適であり続けることはない。例えば、

- 顧客行動変化
- 市場価格変化
- 金利変動
- 新サービス導入

などにより、データ分布自体が変化する。

また、モデル利用方法が変わることで、求められる性能も変化する。例えば、最初は分析用途だったモデルが、後にリアルタイム審査へ利用される場合、速度要求や安定性要求が大きく変化する。

そのため、モデル改善は一度限りの作業ではなく、継続的な改善プロセスとなる。

実習問題：Telco Customer Churn

解答 8.22

False Negative は、実際には解約する顧客を見逃すことである。解約防止施策を実施できないため、本来防げたかもしれない解約を放置することになる。一方、False Positive は、実際には解約しない顧客に施策を実施することである。この場合、施策コストが無駄になる可能性がある。解約予測では、False Negative は機会損失、False Positive は施策コストとして解釈できる。したがって、単に正解率を見るだけでなく、どちらの誤りがビジネス上より深刻かを考える必要がある。

解答 8.23

False Negative の顧客を分析することで、モデルが見逃しやすい解約顧客の特徴を把握できる。例えば、

- ・ 契約期間が中程度で、典型的な短期解約顧客に見えない
- ・ 月額料金が平均的で、料金面のリスクが目立たない
- ・ 長期契約ではないが、明確な高リスク特徴も持たない

といった顧客が見逃される可能性がある。このような分析により、現在の特徴量では捉えきれない解約要因を推測できる。例えば、問い合わせ履歴、通信品質、競合キャンペーン接触などの追加情報が必要かもしれない。

解答 8.24

閾値付近の顧客は、モデルにとって判断が難しい顧客である。この場合、少し閾値を変えるだけで分類結果が変わるため、モデルの確信度は高くない。

一方、高い確信度で誤分類された顧客は、モデルが強く誤った判断をしているケースである。これは、

- ・ 重要な特徴量が不足している
- ・ 訓練データに似た事例が少ない
- ・ データにノイズやラベル誤りがある

可能性を示す。したがって、誤分類を分析する際は、単に間違えたかどうかだけでなく、モデルがどの程度の確信を持って間違えたかを見ることが重要である。

解答 8.25

セグメント別に評価することで、全体指標では見えない性能差を確認できる。例えば、全体 AUC や F1-score が良好であっても、短期契約顧客では Recall が高い一方、中期契約顧客では Recall が低い可能性がある。また、月額料金が低い顧客では解約傾向が強いいため予測しやすいが、料金が中程度の顧客では特徴が曖昧で予測が難しい場合がある。このように、セグメント別評価により、どの顧客群に対して追加特徴量や別モデルが必要かを考えることができる。

解答 8.26

改善仮説の例として、以下が考えられる。

- ・ 契約期間と月額料金の交互作用特徴量を追加する。短期契約かつ高料金の顧客をより明確に捉えられる可能性がある。
- ・ Contract や PaymentMethod などのカテゴリ変数について、解約率ベースのターゲットエンコーディングを試す。カテゴリごとのリスク差をより直接的に表現できる可能性がある。
- ・ class weight を調整し、解約顧客の見逃しを減らす。Recall 向上が期待できるが、Precision

低下に注意が必要である。

- 勾配ブースティングなど非線形モデルを用いる。特徴量間の複雑な関係を捉えられる可能性がある。

各改善案は、検証データまたは交差検証により評価する。評価指標としては、AUC だけでなく、Recall、Precision、F1-score、施策利益などを併せて確認する。

解答 8.27

特徴量の例として、以下が考えられる。

- `TotalCharges / tenure`：実質的な平均月額料金を表す。
- `MonthlyCharges` が高いかどうかを表すフラグ：高料金顧客の不満や競合流出リスクを捉える可能性がある。
- `tenure` が短いかどうかを表すフラグ：新規顧客の早期解約リスクを捉える。
- `Contract` と `MonthlyCharges` の組み合わせ：月次契約かつ高料金の顧客は解約しやすい可能性がある。

重要なのは、単に特徴量を増やすことではなく、誤差分析や業務仮説に基づいて作成することである。また、追加特徴量がモデル性能にどの程度寄与するかを検証することも重要である。

解答 8.28

複数モデルが同じ顧客を誤分類している場合、その顧客は現在の特徴量では判別が難しい可能性がある。この場合、単純なアンサンブルでは大きな改善は期待しにくい。

一方、モデルごとに誤分類している顧客が異なる場合、各モデルが異なる情報や構造を捉えている可能性がある。この場合、予測確率の平均やスタッキングなどのアンサンブルにより性能改善が期待できる。

アンサンブルを検討する際は、単一モデルより性能が向上するだけでなく、推論時間、解釈性、運用複雑性も考慮する必要がある。

実習問題：House Prices

解答 8.29

残差の平均が 0 に近ければ、全体として大きな偏りは少ないと考えられる。残差の平均が正であれば、実際価格より低く予測している傾向、すなわち過小評価が多いことを意味する。一方、残差の平均が負であれば、実際価格より高く予測している傾向、すなわち過大評価が多いことを意味する。また、残差分布が大きく歪んでいる場合や外れ値が存在する場合、特定の価格帯や物件タイプで大きな誤差が発生している可能性がある。

解答 8.30

価格帯別に評価することで、どの領域でモデルが弱いかを確認できる。例えば、全体 RMSE が良好でも、高価格帯で RMSE が大きい場合、高額物件の査定では実務上問題がある。また、高価格帯で平均残差が正の場合、モデルは高額物件を過小評価しやすい。これは、本来より安い価格を提示してしまうリスクにつながる。一方、低価格帯で過大評価が多い場合、売れ残りや価格改定が増える可能性がある。このように、価格帯別評価は、平均指標だけでは見えない改善ポイントを特定するために重要である。

解答 8.31

大きな誤差が発生している物件には、以下のような特徴がある可能性がある。

- 非常に広い、または狭い物件
- 高級地域または特殊地域にある物件
- 築年数が極端に古い、または新しい物件
- 品質評価と価格が通常の関係から外れている物件

これらは、モデルが一般的な傾向では捉えにくい物件である可能性がある。原因としては、特徴量不足、データ数不足、外れ値、特殊物件などが考えられる。

解答 8.32

改善仮説の例として、以下が考えられる。

- SalePrice を対数変換する。高価格帯の影響を緩和し、残差分布を安定化できる可能性がある。
- GrLivArea や LotArea を対数変換する。右に裾の長い特徴量をモデルが扱いやすくてできる可能性がある。
- Neighborhood ごとの平均価格特徴量を追加する。立地による価格差をより明確に表現できる可能性がある。
- 築年数やリフォーム年数に関する特徴量を追加する。物件の新しさを更新状態をより適切に表現できる可能性がある。
- 高価格帯に特化したモデルまたは補正を検討する。高額物件の誤差が大きい場合に有効である。

各改善案は、検証データまたは交差検証で評価し、RMSE、MAE、価格帯別誤差、Business Loss を比較する。

解答 8.33

特徴量の例として、以下が考えられる。

- 建物の築年数：YrSold - YearBuilt

- リフォーム後経過年数： $\text{YrSold} - \text{YearRemodAdd}$
- 総面積： $\text{GrLivArea} + \text{TotalBsmtSF}$
- 1台あたりガレージ面積： $\text{GarageArea} / \text{GarageCars}$
- バスルーム総数： $\text{FullBath} + 0.5 \times \text{HalfBath}$
- 敷地に対する居住面積比： $\text{GrLivArea} / \text{LotArea}$
- 品質と面積の交互作用： $\text{OverallQual} \times \text{GrLivArea}$

これらは、物件の広さ、品質、新しさ、設備水準などをより直接的に表現するため、価格予測に有効となる可能性がある。また、誤差分析で特定の特徴が不足していると推測された場合、その特徴を作成することで性能改善が期待できる。特徴量追加後は、必ず検証データで性能を評価し、追加特徴量の寄与を確認することが重要である。

解答 8.34

複数モデルが同じ物件で大きく外している場合、その物件は現在の特徴量では説明しにくい特殊物件である可能性がある。この場合、単純なアンサンブルでは大きな改善は期待しにくい。一方、モデルごとに大きく外している物件が異なる場合、各モデルが異なるパターンを捉えている可能性がある。この場合、予測値の平均や重み付き平均により、誤差を相殺できる可能性がある。ただし、アンサンブルは推論時間や解釈性に影響するため、性能向上幅と運用コストを比較する必要がある。

第9章 総合演習